

단원명	텍스트 데이터 처리	학년		이름	
학습내용	비정형 텍스트와 집합				
학습목표	집합과 벡터를 이용하여 텍스트 데이터를 목적에 맞게 표현하고 이를 특성에 따라 분석한다.				

활동1

비정형 텍스트 데이터

데이터의 종류	특징
정형 데이터	정해진 형식으로 저장됨.
비정형 데이터	정해진 형식이 없음

문제1. 다음 텍스트 데이터를 정형 데이터와 비정형 데이터로 구분하시오.

ㄱ. 학번

ㄴ. 자기소개서

ㄷ. 주소

ㄹ. 기사 제목

ㅁ. 학년

ㅂ. 블로그 글

정형데이터	비정형데이터
장점:	장점:
단점:	단점:

※ 집합이란?

어떤 기준에 따라 대상을 분명하게 정할 수 있을 때, 그 대상들의 모임을 ‘집합’이라고 한다.

이때 집합을 이루는 대상 하나하나를 그 집합의 원소라고 하며, 모든 원소는 { }안에 나열하여 나타내며, 같은 원소를 중복하여 나열하지 않는다.

문제1. 다음 두 문장 A, B에 포함된 명사들의 모임을 각각 집합 A, B라고 할 때, 물음에 답하시오.

문장 A: 원숭이가 좋아하는 과일은 사과, 바나나, 망고이다.

문장 B: 코끼리가 좋아하는 과일은 사과, 바나나, 수박이다.

Quiz 두 집합 A, B를 각각 원소나열법으로 나타내시오.

※ 데이터 전처리란?



텍스트를 분석하기 위해서는 여러 단계를 거치는데, 데이터를 우선 수집하고, 분석하기에 알맞은 형태로 바꾸는 전처리 단계가 진행된다. 전처리 단계를 거치고 난 이후 데이터를 시각화하고, 분석하는 단계가 진행된다.

전처리 과정엔 불용어를 제거해서 명사, 동사, 형용사 등 사용자의 목적에 적합한 단어를 추출해야한다.

문장	이 치킨은 맛이 좋고 양도 많아요.								
어절 분리	이	치킨은		맛이		좋고	양도		많아요
사전형 단어로 변경	이	치킨	은	맛	이	좋다	양	도	많다
불용어 제거	이	치킨	은	맛	이	좋다	양	도	많다
단어 추출	치킨, 맛, 좋다, 양, 많다								

후기 A	이 노트북은 디자인이 좋아요.
후기 B	이 노트북은 가벼워서 만족합니다.
후기 C	화면이 커서 만족해요. 배송도 빨라요.

문제1.

위 표에 제시된 후기에서 어절을 분리해, 불용어를 제거해 집합으로 나타내시오.

A = {노트북, 디자인, 좋다 }

B = { }

C = { }

문제2. [문제1]에서 $U = A \cup B \cup C$ 라고 할 때,

$U = \{ \}$

나타내시오.

단원명	텍스트 데이터 처리	학년		이름	
학습내용	비정형 텍스트와 집합				
학습목표	집합과 벡터를 이용하여 텍스트 데이터를 목적에 맞게 표현하고 이를 특성에 따라 분석한다.				

문제3. 다음은 연극 관람을 위해 찾아본 후기 텍스트 데이터이다. 물음에 답하시오.

후기 A	주인공이 연기를 잘하고 코믹해서 재미있어요.
후기 B	연극이 웃겨서 즐거웠어요.
후기 C	너무 재미있어서 추천해요.

(1). 세 후기 A, B, C에서 불용어를 제거하고 남은 단어를 원소로하는 세 집합 A, B, C 를 각각 구하시오.

$A = \{ \hspace{10em} \}$
 $B = \{ \hspace{10em} \}$
 $C = \{ \hspace{10em} \}$

(2). 단어 집합(사전) U 를 구하시오.

※ 벡터란?

이름	성별	나이	거주지	직업	스마트폰 이용 요금(단위: 천 원)	스마트폰 자료 사용량(G)
최민준	M	32	수원	회사원	90	8
방정화	F	18	서울	학생	47	2
김하늘	M	28	마포	자영업	55	3
...	...	...	...	...	...	...

위의 표에서 세 사람의 나이, 요금, 자료 사용량을 순서쌍으로 $(32, 90, 8), (18, 47, 2), (28, 55, 3)$ 과 같이 자료 여러개를 순서쌍의 형태로 표현한 것을 벡터라고 한다.

성분이 a_1, a_2 의 2개로 이루어진 벡터는 (a_1, a_2)
 성분이 a_1, a_2, a_3 의 3개로 이루어진 벡터는 (a_1, a_2, a_3)
 마찬가지로 $a_1, a_2, \dots, a_n$ 의 n 개의 성분으로 이루어진 벡터는 $\vec{A} = (a_1, a_2, \dots, a_n)$ 과 같이 나타낸다.
 이때, $a_1, a_2, \dots, a_n$ 을 벡터 $\vec{A}$ 의 성분이라 하고, a_1 을 첫째성분, x_2 를 둘째성분, x_n 을 n 째 성분이라고 한다.

※ 보통 알파벳위에 화살표를 붙여서 나타내고, 성분의 개수를 그 벡터의 '차원'이라고 한다.

문제 1. 벡터 $\vec{X} = (1, 0, 2, 3)$ 에 대해, 다음을 구하시오.

- (1). 벡터 $\vec{X}$ 의 둘째 성분
- (2). 벡터 $\vec{X}$ 의 넷째 성분
- (3). 벡터 $\vec{X}$ 의 차원은 몇인가?

준비사항

- ① <https://tjdgus1121.github.io>에 접속 후 텍스트 분석