

단원명	텍스트 데이터 처리	학년		이름	
학습내용	벡터와 빈도수벡터				
학습목표	집합과 벡터를 이용하여 텍스트 데이터를 목적에 맞게 표현하고 이를 특성에 따라 분석한다.				

활동2

TF와 TF-IDF

후기 A	이 노트북은 디자인이 좋아요.
후기 B	이 노트북은 가벼워서 만족합니다.
후기 C	화면이 커서 만족해요. 배송도 빨라요.

복습1.

위 표에 제시된 후기에서 어절을 분리해, 불용어를 제거해 집합으로 나타내시오.

$A = \{\text{노트북, 디자인, 좋다}\}$
 $B = \{\hspace{10em}\}$
 $C = \{\hspace{10em}\}$

복습2. [문제1]에서 $U = A \cup B \cup C$ 라고 할 때,

$U = \{\hspace{10em}\}$

나타내시오.

컴퓨터는 이진법으로 데이터를 표현한다고 할 때,

1 = 데이터가 ☐

0 = 데이터가 ☐ 일 때를 나타낸다.

	노트북	디자인	좋다	가볍다	만족	화면	크다	배송	빠르다
A									
B									
C									

세 집합 A, B, C 에 대응하는 수를 순서대로 성분으로 하는 벡터로 각각 나타내면

$\vec{a} = (\hspace{10em})$
 $\vec{b} = (\hspace{10em})$
 $\vec{c} = (\hspace{10em})$

문제1. 세 영화 후기 A, B, C에서 불용어를 제거하고 남은 단어를 원소로 하는 세 단어집합을 각각 A, B, C 라고 하자. 세 집합 A, B, C 의 합집합 U 가 다음과 같을 때, 물음에 답하시오.

후기 A	일단 추천! 눈물 나는 감동적인 영화!
후기 B	지루해서 잠이 오는 영화
후기 C	스토리와 연기에 감동!

(1). 세 후기 A, B, C에서 불용어를 제거하고 남은 단어를 원소로하는 세 집합 A, B, C 를 각각 구하시오.

$A = \{\hspace{10em}\}$
 $B = \{\hspace{10em}\}$
 $C = \{\hspace{10em}\}$

(2). 단어 집합(사전) U 를 구하시오.

A									
B									
C									

세 집합 A, B, C 에 대응하는 수를 순서대로 성분으로 하는 벡터로 각각 나타내면

$\vec{a} = (\hspace{10em})$
 $\vec{b} = (\hspace{10em})$
 $\vec{c} = (\hspace{10em})$

단원명	텍스트 데이터 처리	학년		이름	
학습내용	벡터와 빈도수벡터				
학습목표	집합과 벡터를 이용하여 텍스트 데이터를 목적에 맞게 표현하고 이를 특성에 따라 분석한다.				

※ 벡터의 연산

두 벡터 $\vec{a} = (a_1, a_2, \dots, a_n), \vec{b} = (b_1, b_2, \dots, b_n)$ 에 대하여 두 벡터의 덧셈과 뺄셈은 다음과 같이 정의한다.

$\vec{a} + \vec{b} = (a_1 + b_1, a_2 + b_2, \dots, a_n + b_n)$

$\vec{a} - \vec{b} = (a_1 - b_1, a_2 - b_2, \dots, a_n - b_n)$

예시) $\vec{a} = (1, 3, 4), \vec{b} = (2, 0, 1)$ 일 때,
 $\vec{a} + \vec{b} = (1 + 2, 3 + 0, 4 + 1) = (3, 3, 5)$

문제1) 두 벡터 $\vec{a} = (1, 2, 3, 4, 5), \vec{b} = (1, 0, -1, 2, -2)$ 에 대해 다음을 구하시오.

- (1) $\vec{a} + \vec{b}$
- (2) $\vec{a} - \vec{b}$

문제2) 두 벡터 $\vec{a} = (1, -4, 3, 6, 2), \vec{b} = (0, 2, -2, 3, -3)$ 에 대해 다음을 구하시오.

- (1) $\vec{a} + \vec{b}$
- (2) $\vec{a} - \vec{b}$

※ 주제어 찾기

후기 A	뷰가 좋아 사진 이 잘 나와요. 깨끗한 캠핑장 에서 사진 찍어요.
후기 B	뷰가 좋고 , 깨끗한 차박 에 좋은 캠핑장 !
후기 C	캠핑장 에 온수 가 잘 나와요. 화장실 도 깨끗하고 온수 가 나와요.

문제1)
단어집합 U에 있는 단어를 순서대로 나열하고, 후기 A, B, C에서 각 단어가 등장하는 단어의 빈도수(TF)를 나타내보자.

	뷰	좋다	사진	깨끗하다	캠핑장	차박	온수	화장실
A								
B								
C								

$\vec{a} = ($ $)$

$\vec{b} = ($ $)$

$\vec{c} = ($ $)$

위의 단어별 빈도수를 성분으로 하는 벡터를 **빈도수벡터(TF벡터)** 라고 한다.

$\vec{u} = \vec{a} + \vec{b} + \vec{c}$ 라 할 때,

$\vec{u} = ($ $)$

단원명	텍스트 데이터 처리	학년		이름	
학습내용	벡터와 빈도수벡터				
학습목표	집합과 벡터를 이용하여 텍스트 데이터를 목적에 맞게 표현하고 이를 특성에 따라 분석한다.				

미세먼지와 관련한 기사 제목 2개를 가져온 것이다.

후기 A	미세먼지 증가, 마스크 착용하세요. 마스크 필수! 꼭 착용!
후기 B	미세먼지로 호흡기 질환이 증가하니 마스크를 착용하세요. 호흡기 질환 조심!

	미세먼지							
A								
B								

문제2) 기사 A, B와 전체 기사를 단어가방을 이용하여 각각 빈도수 벡터로 나타내시오.

$\vec{a} = ($ $)$

$\vec{b} = ($ $)$

$\vec{u} = ($ $)$

위를 빈도수 벡터를 참고하여 각 기사의 주제어를 찾아보고, 전체 주제어를 적으시오.

뉴스 기사 수백 개를 한꺼번에 읽는 일은 쉽지 않다. 그런데 컴퓨터는 글을 “읽는” 대신, 먼저 단어를 센다. 어떤 단어가 많이 나오면 더 중요하다고 보고, 그것을 크게 보여 준 것이 바로 워드클라우드이다. 즉, 워드클라우드의 예쁜 그림이 아니라, 글 속 단어의 등장 횟수(TF)를 눈으로 보이게 만든 결과이다. 결국 컴퓨터는 문장을 이해하기 전에, 먼저 단어를 숫자로 바꾸는 일부터 시작하는 셈이다.

미국과 이란의 종전 협상 결렬로 오르무즈 해협을 둘러싼 긴장이 급격히 고조되고 있다. 미국은 13일 오르무즈 해협을 중심으로 대이란 해상 봉쇄를 시작하며, 미승인 선박에 대한 차단·회항·나포 조치를 발표했다. 도널드 트럼프 대통령은 이란 함정이 봉쇄 구역에 접근할 경우 즉시 격침하겠다는 강경한 입장을 밝혔다. 이에 따라 오르무즈 해협을 통과하던 유조선들이 안전 우려로 회항하거나 대기하는 사례가 증가하고 있다. 로이터 통신 등 외신 보도에 따르면, 세계 원유·가스 물동량의 20%가 통과하는 이 해협의 교통이 경색되며 에너지 공급 차질 우려가 커지고 있다. 미-이란 간 전쟁 재연 가능성과 극적 협상 타결 전망 등 다양한 시나리오가 점쳐지는 가운데, 지역 안정성은 크게 흔들린 상태다.

