

단원명	텍스트 데이터 처리	학년		이름	
교과서					
학습목표	집합과 벡터를 이용하여 텍스트 데이터를 목적에 맞게 표현하고 이를 특성에 따라 분석한다.				

준비사항

① <https://tjdigus1121.github.io>에 접속 후 텍스트 분석

활동1	비정형 텍스트 데이터
-----	-------------

- 빅카인즈(bigkinds)에 접속하여 [뉴스보기] - [주간이슈] 중 관심 가는 뉴스를 읽어봅시다. (3분)
- 학생이 관심가는 뉴스의 제목은 무엇인가요?
- 본인이 직접 고른 뉴스의 주제는 한단어, 한문장으로 무엇인가요?
- tjdigus1121.github.io에 접속하여 텍스트분석 접속 → TF-IDF 클릭합니다.
- 빅카인즈(bigkinds)에서 읽은 뉴스를 복사 (Ctrl+C)하여, 붙여넣기(Ctrl+V) 합니다.

활동1. 뉴스를 분석하고 등장한 몇 개 단어를 고르고 이
에 대한 TF, DF, IDF를 찾아 적어봅시다.

단어	TF	DF	IDF

활동2. 각 단어별 TF·IDF 위의 표를 참고하여 직접 계
산하여 봅시다.

단어	TF·IDF

친구와 활동지를 바꾸고, 위의 표를 근거로하여
뉴스제목을 추측해봅시다.

추가 개념

TF-IDF는 말뭉치에서 특정 단어가 얼마나 중요한지를 수치로 나타낸 것이다. 그런데 인공지능이 다루는 문서의 전체 개수 n 은 보통 상상할 수 없을 만큼 크다.

만약 IDF를 그냥 $\frac{n}{DF}$ 로 계산하면, 값이 너무 커져서 단어의 중요도가 마치 “폭주”하듯 튀어 버린다. 그래서 로그를 사용한다. 로그는 숫자가 커질수록 증가 속도를 부드럽게 눌러 주는 브레이크 역할을 한다.

예를 들어 $n = 10^6$, $DF = 10^2$ 이면, $\frac{n}{DF} = 10^4$ 이지만, 로그를 씌우면 단숨에 4로 정리되어 비교와 계산이 쉬워진다.

단원명	텍스트 데이터 처리	학년		이름	
교과서					
학습목표	집합과 벡터를 이용하여 텍스트 데이터를 목적에 맞게 표현하고 이를 특성에 따라 분석한다.				

※ 벡터란?

이름	성별	나이	거주지	직업	스마트폰 이용 요금(단위: 천 원)	스마트폰 자료 사용량(G)
최민준	M	32	수원	회사원	90	8
방정화	F	18	서울	학생	47	2
김하늘	M	28	마포	자영업	55	3
...	...	...	...	...	...	...

위의 표에서 세 사람의 나이, 요금, 자료 사용량을 순서쌍으로 (32, 90, 8), (18, 47, 2), (28, 55, 3)과 같이 나타낸 자료를 살펴보자. 이처럼 자료 여러개를 순서쌍의 형태로 표현한 것을 **벡터**라고 한다.

성분이 a_1, a_2 의 2개로 이루어진 벡터는 (a_1, a_2)

성분이 a_1, a_2, a_3 의 3개로 이루어진 벡터는 (a_1, a_2, a_3)

마찬가지로 $a_1, a_2, \cdots, a_n$ 의 n 개의 성분으로 이루어진 벡터는 $(a_1, a_2, \cdots, a_n)$ 과 같이 나타낸다.