

단원명	텍스트 데이터 처리	학년		이름	
학습내용	TF·IDF				
학습목표	집합과 벡터를 이용하여 텍스트 데이터를 목적에 맞게 표현하고 이를 특성에 따라 분석한다.				

활동4	TF와 TF-IDF
-----	------------

※ 주제어 찾기

후기 A	뷰가 좋아 사진 이 잘 나와요. 깨끗한 캠핑장 에서 사진 찍어요.
후기 B	뷰가 좋고 , 깨끗한 차박 에 좋은 캠핑장 !
후기 C	캠핑장 에 온수 가 잘 나와요. 화장실 도 깨끗하고 온수 가 나와요.

단어빈도(TF): 각 문서에 등장하는 단어들의 빈도수이다.

복습)

단어집합 U 에 있는 단어를 순서대로 나열하고, 후기 A, B, C에서 각 단어가 등장하는 단어의 빈도수(TF)를 나타내보자.

	뷰	좋다	사진	깨끗하다	캠핑장	차박	온수	화장실
A					1			
B					1			
C					1			

$\vec{a} = ($)
 $\vec{b} = ($)
 $\vec{c} = ($)

문서빈도(DF): 단어별로 그 단어가 등장하는 문서의 개수이다.

	뷰	좋다	사진	깨끗하다	캠핑장	차박	온수	화장실
DF					3			1

예를 들어 ‘캠핑장’은 모든 문서에 등장했으므로 DF는 3이고, ‘화장실’은 후기 C에서만 등장했으므로 DF는 1이다.

※ 나머지를 직접 채워보세요!

역문서빈도(IDF): 전체 문서의 개수를 n 이라 할 때, $\frac{n}{DF}$ 이 IDF이다.

	뷰	좋다	사진	깨끗하다	캠핑장	차박	온수	화장실
IDF					1			3

전체 문서(후기 개수)가 3이므로 ‘캠핑장’은 $\frac{3}{3} = 1$ 이다.

그리고 ‘화장실’은 $\frac{3}{1} = 3$ 이다.

※ 나머지를 직접 채워보세요!

TF·IDF): $TF \times IDF$ 의 값이다.

	뷰	좋다	사진	깨끗하다	캠핑장	차박	온수	화장실
TF·IDF(A)					1			
TF·IDF(B)								
TF·IDF(C)								3

A에서 ‘캠핑장’의 TF가 1이고, IDF가 1이므로 TF·IDF(A)에서 ‘캠핑장’은 1이다.

C에서 ‘화장실’의 TF가 1이고 IDF가 3이므로 TF·IDF(C)는 3이다.

※ 나머지를 직접 채워보세요!

단원명	텍스트 데이터 처리	학년		이름	
학습내용	TF·IDF				
학습목표	집합과 벡터를 이용하여 텍스트 데이터를 목적에 맞게 표현하고 이를 특성에 따라 분석한다.				

[문제]

문장 1	AI는 데이터를 분석하고 데이터를 학습해 모델을 만든다.
문장 2	AI 모델은 이미지를 분석하고, 이미지를 학습한다.
문장 3	수학은 데이터를 분석하고, 데이터 모델을 설명한다.
문장 4	AI는 수학 모델로 이미지를 학습한다.

TF

TF	AI	데이터	이미지	수학	분석	모델	학습
1							
2							
3							
4							

DF

단어	AI	데이터	이미지	수학	분석	모델	학습
DF							

IDF

단어	AI	데이터	이미지	수학	분석	모델	학습
IDF							

TF·IDF

TF	AI	데이터	이미지	수학	분석	모델	학습
TF·IDF(1)							
TF·IDF(2)							
TF·IDF(3)							
TF·IDF(4)							

해석 정리

TF	문서 안에서 단어가 나온 횟수	많이 나올수록 문서와 관련이 깊을 가능성이 있음
DF	그 단어가 등장한 문서의 수	여러 문서에 나오면 흔한 단어니 중요 단어는 아닐 가능성
IDF	DF의 역수, 로그	흔한 단어의 영향력을 줄이고, 자주 등장하지 않는 드문단어 높게 평가
TF·IDF	TF(각 문장) IDF(문서전체)를 비교하여 곱함	많이나오고 동시에 흔치 않는 단어를 곱했을 때 값이 높으면 중요함.