

단원명	텍스트 데이터 처리	학년		이름	
교과서					
학습목표	집합과 벡터를 이용하여 텍스트 데이터를 목적에 맞게 표현하고 이를 특성에 따라 분석한다.				

준비사항

- ① <https://tjdgus1121.github.io>에 접속 후 텍스트 분석

활동1

비정형 텍스트 데이터


1. 활동2 유사도 분석에 접속하고, 방코드를 입력하세요.
2. 선생님이 올린, 사진을 보고 떠오르는 문장을 적어서 제출하세요.
3. 워드클라우드에 가장 큰 단어는 무엇이며, 그 단어가 가장 큰 이유는 무엇이라 생각하나요?
4. 본인이 제출한 문장의 TF 벡터는 무엇인가요?
5. 웹어플을 활용하여 유클리드유사도와 코사인유사도로 바라본 가장 유사한 문장은 무엇인가요?

삼각형 ABC는 직각삼각형이므로 피타고라스 정리에 의하여

$$\begin{aligned}\overline{AB}^2 &= \overline{AC}^2 + \overline{BC}^2 \\ &= (x_2 - x_1)^2 + (y_2 - y_1)^2\end{aligned}$$

이다. 따라서 두 점 A, B 사이의 거리는 다음과 같다.

$$\overline{AB} = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$



좌표평면 위의 두 점 사이의 거리

좌표평면 위의 두 점 $A(x_1, y_1)$, $B(x_2, y_2)$ 사이의 거리는

$$\overline{AB} = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

1. 유클리드 유사도

두 텍스트 P와 Q를 나타내는 벡터가 각각

$$\vec{P} = (p_1, p_2, \dots, p_n), \quad \vec{Q} = (q_1, q_2, \dots, q_n)$$

일 때, P와 Q의 유클리드 유사도를 기호로 $L(P, Q)$ 와 같이 나타내고


$$L(P, Q) = \sqrt{(p_1 - q_1)^2 + (p_2 - q_2)^2 + \dots + (p_n - q_n)^2}$$

과 같이 정한다.

(예시)

두 텍스트 P, Q를 나타내는 벡터가 $\vec{P} = (4, 1)$ 과

$\vec{Q} = (1, 5)$ 일 때, P와 Q의 유클리드 유사도 $L(P, Q)$ 는 다음과 같다.



$$L(P, Q) = \sqrt{(4-1)^2 + (1-5)^2} = \sqrt{25} = 5$$

단원명	텍스트 데이터 처리	학년		이름	
교과서					
학습목표	집합과 벡터를 이용하여 텍스트 데이터를 목적에 맞게 표현하고 이를 특성에 따라 분석한다.				

예제1. 세 텍스트 P, Q, R를 나타내는 벡터가 다음과 같을 때, 유클리드 유사도를 이용하여 가장 유사한 텍스트 두 개를 고르시오.

$$\vec{P}=(1, 0, 1), \quad \vec{Q}=(0, 1, 2), \quad \vec{R}=(1, 1, 0)$$

L(P, Q)	
L(Q, R)	
L(R, P)	

문제1. 벡터 A, B, C가 다음과 같을 때, 유클리드 유사도를 이용하여 가장 유사한 텍스트 두 개를 고르시오.


$$A=(1, 2, 0, 1, 3)$$

$$B=(2, 2, 1, 1, 2)$$

$$C=(5, 0, 3, 4, 0)$$

L(A, B)	
L(A, C)	
L(B, C)	


※ 벡터의 크기
오른쪽 그림과 같이 좌표평면에서 $\vec{a}=(a_1, a_2)$ 일 때, 원점 O와 점 $A(a_1, a_2)$ 에 대하여, $\vec{a}=\overrightarrow{OA}$ 이므로, 벡터 $\vec{a}$ 의 크기는 선분 OA의 길이와 같다. 즉,



$$|\vec{a}|=\sqrt{a_1^2+a_2^2}$$

예시) $\vec{a}=(1, 2, 3, 4)$ 라 하면
 $|\vec{a}|=\sqrt{1^2+2^2+3^2+4^2}=\sqrt{30}$ 이다.

※ 내적의 정의
영벡터가 아닌 두 벡터 $\vec{a}, \vec{b}$ 가 이루는 각의 크기가 θ 일 때 $|\vec{a}||\vec{b}|\cos\theta$ 를 $\vec{a}$ 와 $\vec{b}$ 의 내적이라고 하고 기호로 $\vec{a}\cdot\vec{b}$ 로 표현한다.



그리고 벡터 $\vec{a}=(a_1, a_2), \vec{b}=(b_1, b_2)$ 라 할 때, $\vec{a}\cdot\vec{b}=a_1b_1+a_2b_2$ 이다.

예시) 세 벡터 A, B, C에 대하여 벡터의 내적은 다음과 같다.

$$A=(1, 2, 3, 1)$$

$$B=(2, 0, 1, 4)$$

$$C=(3, 1, 2, 0)$$

$$A\cdot B=1\times2+2\times0+3\times1+1\times4=9$$

$$A\cdot C=1\times3+2\times1+3\times2+1\times0=11$$

$$B\cdot C=2\times3+0\times1+1\times2+4\times0=8$$

단원명	텍스트 데이터 처리	학년		이름	
교과서					
학습목표	집합과 벡터를 이용하여 텍스트 데이터를 목적에 맞게 표현하고 이를 특성에 따라 분석한다.				

2. 코사인 유사도

두 텍스트 P와 Q를 나타내는 벡터가 각각
 $\vec{P}=(p_1, p_2, \cdots, p_n), \vec{Q}=(q_1, q_2, \cdots, q_n)$
일 때, P와 Q의 코사인 유사도를 기호로 $C(P, Q)$ 와 같이 나타내고

$$C(P, Q)=\frac{p_1q_1+p_2q_2+\cdots+p_nq_n}{\sqrt{p_1^2+p_2^2+\cdots+p_n^2}\sqrt{q_1^2+q_2^2+\cdots+q_n^2}}$$
과 같이 정한다.

코사인 유사도 : 내적 ÷ 크기

(예시)

두 텍스트 P, Q를 나타내는 벡터가 $\vec{P}=(2, 1)$ 과 $\vec{Q}=(1, 3)$ 일 때, P와 Q의 코사인 유사도 $C(P, Q)$ 는 다음과 같다.

$$C(P, Q)=\frac{2\times 1+1\times 3}{\sqrt{2^2+1^2}\sqrt{1^2+3^2}}=\frac{1}{\sqrt{2}}$$

연습1. 세 텍스트 P, Q, R를 나타내는 벡터가 다음과 같을 때, 코사인 유사도를 이용하여 가장 유사한 텍스트 두 개를 고르시오.

$$\vec{P}=(1, 1, 0), \vec{Q}=(2, 0, 0), \vec{R}=(1, 0, 2)$$

각 벡터의 크기 :

각 벡터의 내적 :

코사인 유사도 :

유사도 기준이 다른 이유

문장은 단어의 등장 횟수를 좌표로 하는 벡터로 표현할 수 있다. 코사인 유사도는 벡터의 방향을 비교해 단어 사용의 비율이 비슷한지를 본다. 반면 유클리드 유사도는 벡터 사이의 거리를 계산해 전체 사용량의 차이를 반영한다. 이 때문에 문장의 길이나 반복 정도에 따라 두 기준은 서로 다른 결과를 낼 수 있다. 시는 목적에 따라, 의미 중심인지 양 중심인지에 맞는 기준을 선택한다.

6. 본인의 문장과 친구가 제출한 가장 유사한 문장 벡터를 통해 아래 칸에 계산과정을 적어봅시다.

유클리드유사도

나의 TF벡터:
친구의 TF벡터:

계산과정:

코사인유사도

나의 TF벡터:
친구의 TF벡터:

계산과정:

7. 유클리드 유사도와 코사인유사도로 계산한 유사문장이 서로 같나요?